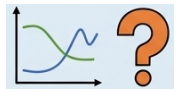
안정동위원소 결합 오염평가 체계 고도화를 위한 국가 수질측정망 적용 연구

국립환경과학원 +Pride
National Institute of Environmental Research

연구의 필요성

기후/토지이용 변화에 따른 비점오염원 특성 복잡화

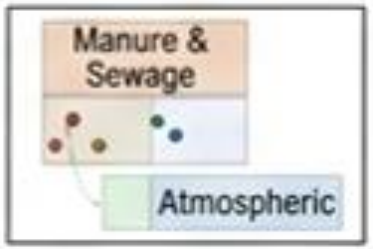


기존 농도 중심 평가:
☞ 정밀한 오염원 기원 및 기여도 규명에 한계



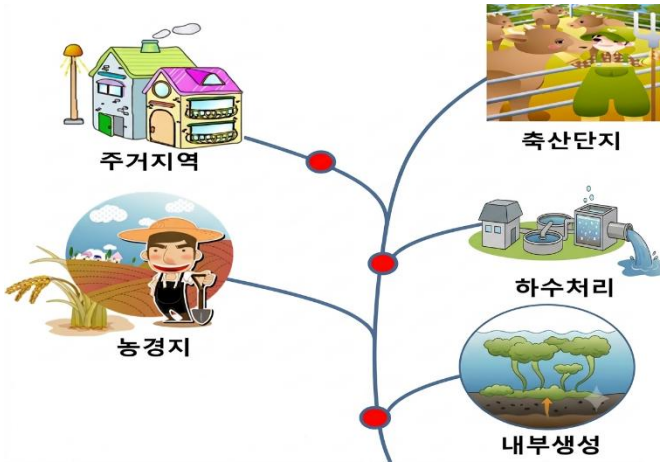
질소(담수 부영양화 & 조류 발생):
☞ 관련 오염원 정량적 평가 체계 미흡

1. 오염원 라이브러리 구축



오염원별(토양, 화학비료, 하수, 분뇨, 강우) 질산염 안정동위원소비 대푯값 결정

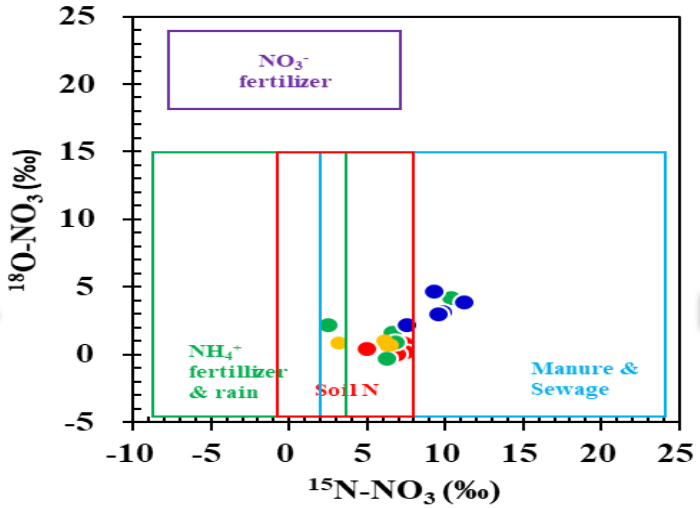
2. 시료 채수 및 분석



- 오염원 주변 지류 및 본류의 혼합지점에서 시료 채수 및 안정동위원소비 분석

  - 국가 수질측정망 지점의 수질 및 안정동위원소비 고빈도 모니터링 (1회/주)

3. 신속한 원인진단(정성적)



- 지점별 실측 안정동위원소비를 오염원 라이브러리 이중 plot에 적용하여 신속 원인진단
- Kendall plot 적용 시 오염원 중첩문제 해결 필요

4. 오염원 기여율 산정(정량적)

MixSIAR(R)

베이지안 추론 기반 통계적 불확실성 바탕 오염원 기여율 산정 혼합모델 도구

EMMTE(Excel)

MixSIAR 모델을 참고한 End-member 혼합모델 도구



지점별 실측 안정동위원소비와 오염원별 (토양, 화학비료, 하수, 분뇨, 강우) 대푯값 적용 후 기여율 산정

<붙임1> 오염원 라이브러리 구축[참고자료: 기술 검토용 세부 프로세스]

국립환경과학원 +Pride
National Institute of Environmental Research

1. 선행연구 데이터 취합 및 데이터베이스 구축

기존 연구과제 및 논문 리뷰 (2019~2025)





2. 오염원 시료 정보 취합 (총 380개)

논문리뷰 73개(화학비료)
센터 수행 연구과제 307개

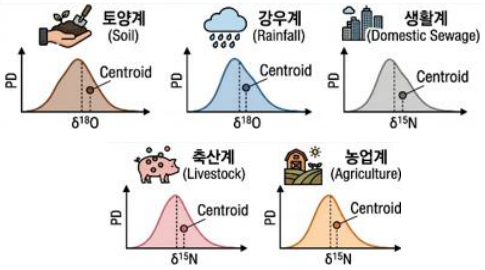
3. 오염원별 대표 시료 선별 및 검증

통계적 기법, Kendall plot 등 검증된 오염원 영역 정보 활용





4. 오염원별 질산염 안정동위원소비 대푯값 결정



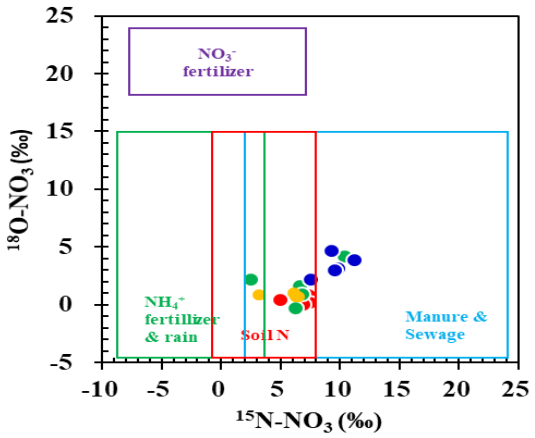
구분	오염원	최종 오염원 범주	Kendall plot
토양계 (27개)	토양, 산림유출수, 산림토(대나무), 하천 및 호소 상류 유출수 등 취합	토양-질소 기원	토양-질소
강우계 (13개)	강우(옥상 채수, 순수, 빗물) 등 취합	강우	강우
생활계 (77개)	하수처리장 유입수 및 방류수, 오염원 주변 지류 및 본류 유입수 및 방류수 등 취합	생활하수(분뇨?)	하수·분뇨
축산계 (47개)	퇴비(부숙, 적치, 시판, 우분, 돈분 등), 가축분뇨, 퇴비 유출수, 가축 처리수 등 취합	축산분뇨	X
농업계 (216개)	유출수(밭, 퇴비, 과수원, 논, 배수로 등), 토양(밭, 논 등), 비닐하우스, 비료(화학, 복합, 시판 등) 등 취합	화학비료 유기질비료(퇴비)	화학비료

<붙임2> 정성적, 정량적 질소 오염원 평가[참고자료: 기술 검토용 세부 프로세스]

국립환경과학원 +Pride
National Institute of Environmental Research

정성적 질소 오염원 평가

오염원 라이브러리 이중 plot 적용
(안정동위원소 기반)



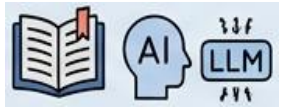
- Kendall plot 적용 시 오염원 중첩문제 해결 필요

문헌지식 기반 AI 오염원 판별 시스템
(수질, 안정동위원소 기반)

입력 모니터링 데이터 전처리 후 연구지점 군집화
(PAM, DIANA 등 8종 ML/AI 경쟁)



국내외 연구문헌 지식 기반 군집 및 개별지점 기준 오염원 1차 결정
(Gemini NLP/LLM 기반 자료 학습)



Gemini

ML/AI 기반 오염원 판별 임계치 보정 및 패턴분석을 통한 최종 오염원 판별
(누락 가능성 높은 핵심 오염 지점 상호보정)



실측자료 기반 AI 오염원 판별 시스템
(수질, 안정동위원소 기반)

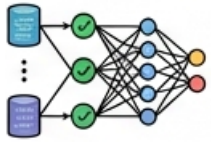
입력 모니터링 데이터 및 학습용 실측자료 전처리, Domain 규칙 및 AI 추론 기반 오염원 범주 라벨링
(Gemma/Gemini API LLM)





Gemma/Gemini

Hybrid Ensemble Model 기반 Soft voting 앙상블 학습
(XGBoost, MLP 등 22종 ML/AI 결합)

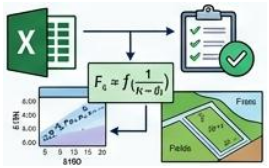


각 연구지점 대상 최종 오염원 판별



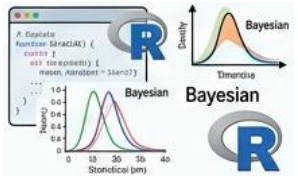
정량적 질소 오염원 평가

모델 간 교차 검증 기반 신속·간편 오염원 기여율 산정 방법 마련



EMMTE
(Excel)

교차 검증



MixSIAR
(R with JAGS)

Excel 기반의 현장 모델 EMMTE 및 R language 기반 범용 모델 MixSIAR 간 교차 검증을 통해 질소 오염원 기여율 산정의 신뢰성 확보

오염원별 기여율 산정



각 오염원별(토양, 화학비료, 하수, 분뇨, 강우) 기여율 산정 및 평가

<붙임3> AI 오염원 평가 시스템 framework [참고자료: 기술 검토용 세부 프로세스]

국립환경과학원 +Pride
National Institute of Environmental Research

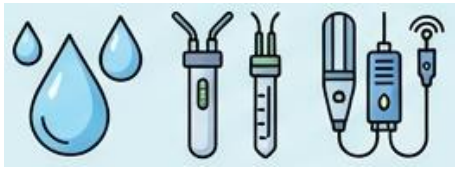
문헌지식 기반 AI 오염원 평가 시스템

데이터 입력 및 문헌 지식 추출



문헌 지식
(SCI 논문 등)
제공

AI(NLP/LLM)
지식 추출,
오염원별
정량적 데이터 범위
구축



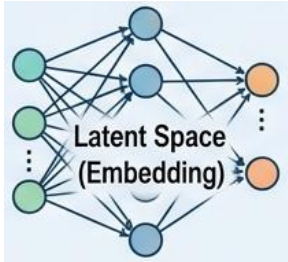
수질 및 질산염 안정동위원소비
측정 데이터 입력

로버스트 결측치 처리
(Robust Imputation)

ROS
(Regression on Order Statistics)
→ 실패 시 Fallback → KNN Imputer → Z-score 정규화

AI 기반 오염원 평가

[비선형 특징 추출]
CINN VAE
(Chemistry-Informed Neural Network based Variational Autoencoder)





도메인 지식
주입

[AI 알고리즘 경쟁 기반 군집화]
8대 AI algorithm 경합



모델 평가 및 최적 군집 수 K 선정
: 복합 평가지표(Concensus Score) 기반
-> Silhouette Score + DBI + CHI

HDBSCAN noise 재할당
: KNN 보정

[지식 주입형 오염원 분석]

국내문헌(Case1)
국외문헌(Case2)
국내+국외(Case3)



KINN 구축
(Knowledge-Informed Neural Network)

XAI(SHAP) 기반 임계치 자가 최적화 feedback

[최종 평가]



AI screening 및
오염원
평가 결과
출력

<붙임4> AI 오염원 평가 시스템 [참고자료: 기술 검토용 세부 프로세스]

국립환경과학원 +Pride
National Institute of Environmental Research

실측자료 기반 AI 오염원 평가 시스템

START

수질 및 질산염 안정동위원소비 측정 데이터 입력
(학습용(train) 및 평가용(test))

STEP1

데이터 전처리 및 특징 추출
(Data preprocessing & Feature extraction)

1) Robust Imputation
(Imputation ROS/KNN)

2) 6대 비율 파생변수 생성
(Derived Ratios: T-N/T-P etc.)

STEP2

하이브리드 의사 라벨링
(Hybrid Pseudo-Labeling)

1) 도메인 룰셋
(Rule-based Filter)

2) LLM Domain 추론

3) 미라벨링 데이터에 적절한 라벨링 부여
(Create Training Data)

STEP3

End-member 기반 데이터 증강
(Data Augmentation)

1) 오염원 범주 기반 불균형 조정
(Class Imbalance Adjustment)

2) Domain profile 활용

STEP4

22대 AI model 앙상블 학습
(Ensemble Learning: 22 Models)



1) Machine Learning/Deep Learning Combination
2) Soft Voting 적용

STEP5

통합 예측 및 Out-of-Distribution 탐지
(Prediction & OOD Detection)

1) 평가 데이터 예측
2) 미학습/복합 오염원(Unknown) 판별

최종 오염원 판별

1) 신뢰도(Confidence) 점수 산출
2) 계층적 분류(Macro Categories)